

第十二章 可行方向法

Zoutendijk可行方向法

一. 线性约束的情形

$$\begin{cases} \min f(x) \\ s.t. \quad Ax \geq b \\ \quad \quad Ex = e \end{cases} \quad (1)$$

其中 $f(x)$ 可微, $A_{m \times n}$, $E_{l \times n}$, $x_{n \times 1}$, $b_{m \times 1}$, $e_{l \times 1}$

$S = \{x \mid Ax \geq b, Ex = e\}$ ———可行域

定义： 对 $\min_{x \in E^n} f(x)$, 设 $\bar{x} \in E^n$ 是任给一点,

$d \neq 0$, 若存在 $\delta > 0$, 使得对任意的 $\lambda \in (0, \delta)$, 有 $f(\bar{x} + \lambda d) < f(\bar{x})$, 则称 d 为 $f(x)$ 在点 \bar{x} 处的下降方向。

$$F_0 = \{d \mid \nabla f(\bar{x})^T d < 0\}$$

称为点 \bar{x} 处的下降方向集。

定义： 设集合 $S \subset E^n$, $\bar{x} \in clS$, d 为非零向量, 若存在数 $\delta > 0$, 使得对任意 $\lambda \in (0, \delta)$, 都有

$$\bar{x} + \lambda d \in S$$

则称 d 为集合 S 在 \bar{x} 的可行方向。

$$D = \left\{ d \mid d \neq 0, \bar{x} \in clS, \exists \delta > 0, \forall \lambda \in (0, \delta), \text{有 } \bar{x} + \lambda d \in S \right\}$$

\bar{x} 处的可行方向锥。

定理1: 设 \bar{x} 是问题(1)的可行解, 在 \bar{x} 点处, 有

$$A_1\bar{x} = b_1, A_2\bar{x} > b_2$$

其中 $A = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix}, b = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$, 则非零向量 d 是 \bar{x} 处的可行方向

的充要条件是 $A_1d \geq 0, Ed = 0$.

证明: “ \Rightarrow ” d 是 \bar{x} 处的可行方向, 则 $\exists \delta > 0$, 对 $\forall \lambda \in (0, \delta)$,

有 $A(\bar{x} + \lambda d) \geq b, E(\bar{x} + \lambda d) = e$

$\Rightarrow A_1(\bar{x} + \lambda d) \geq b_1, E\bar{x} + \lambda Ed = e$

$\because \bar{x}$ 为可行解, 且 $A_1\bar{x} = b_1, E\bar{x} = e$,

$\therefore \lambda A_1d \geq 0, \lambda Ed = 0,$

$\because \lambda > 0, \therefore A_1d \geq 0, Ed = 0$ 。

$$\begin{cases} \min f(x) \\ s.t. \quad Ax \geq b \\ \quad \quad Ex = e \end{cases}$$

定理1: 设 \bar{x} 是问题(1)的可行解,在 \bar{x} 点处,有

$$A_1\bar{x} = b_1, A_2\bar{x} > b_2$$

其中 $A = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix}, b = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$,则非零向量 d 是 \bar{x} 处的可行方向

的充要条件是 $A_1d \geq 0, Ed = 0$.

证明: “ \Leftarrow ” 设 $A_1d \geq 0, Ed = 0$

$\because A_2\bar{x} > b_2, \therefore \exists \delta > 0$,使得对 $\forall \lambda \in (0, \delta)$, 有

$$A_2(\bar{x} + \lambda d) \geq b_2$$

由假设 $A_1\bar{x} = b_1, A_1d \geq 0 \therefore A_1(\bar{x} + \lambda d) \geq b_1 \Rightarrow A(\bar{x} + \lambda d) \geq b$

又由 $Ed = 0, E\bar{x} = e \Rightarrow E(\bar{x} + \lambda d) = e$

$\therefore \bar{x} + \lambda d$ 是(1)的可行解,因此 d 是可行方向.

$$\begin{cases} \min f(x) \\ s.t. \quad Ax \geq b \\ \quad \quad Ex = e \end{cases}$$

$$(2) \quad \begin{cases} \min \nabla f(x)^T d \\ s.t. \quad A_1 d \geq 0 \\ \quad \quad Ed = 0 \\ \quad \quad |d_j| \leq 1, j = 1, 2, \dots, n \end{cases}$$

定理2: 在问题(1)中, 设 x 是可行解, 在点 x 处有

$A_1x = b_1, A_2x > b_2$, 其中

$$A = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix}, \quad b = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix},$$

$$\begin{cases} \min \nabla f(x)^T d \\ \text{s.t. } A_1 d \geq 0 \\ \quad \quad Ed = 0 \\ \quad \quad |d_j| \leq 1, j = 1, 2, \dots, n \end{cases}$$

则 x 是KKT点的充要条件是问题(2)的目标函数最优值 = 0。

证明: x 是KKT点 \Leftrightarrow 存在向量 $w \geq 0, v$, 使得

$$\nabla f(x) - A_1^T w - E^T v = 0$$

令 $v = p - q, p, q \geq 0$, 把上式写成

$$(*) \quad \left\{ \begin{array}{l} \begin{pmatrix} -A_1^T & -E^T & E^T \end{pmatrix} \begin{pmatrix} w \\ p \\ q \end{pmatrix} = -\nabla f(x) \\ \begin{pmatrix} w \\ p \\ q \end{pmatrix} \geq 0 \end{array} \right. \quad \left\{ \begin{array}{l} \min \nabla f(x)^T d \\ s.t. \quad A_1 d \geq 0 \\ \quad \quad Ed = 0 \\ \quad \quad |d_j| \leq 1, j = 1, 2, \dots, n \end{array} \right.$$

由Farkas引理, $(*)$ 有解 $\Leftrightarrow \begin{pmatrix} -A_1 \\ -E \\ E \end{pmatrix} d \leq 0, \quad -\nabla f(x)^T d > 0$

无解, 即 $\nabla f(x)^T d < 0, A_1 d \geq 0, Ed = 0$ 无解,
等价于问题(2)目标函数最优值 = 0。

步长的确定

设 $x^{(k)}$ 是问题(1)的可行解, $d^{(k)}$ 是下降可行方向, 从 $x^{(k)}$ 出发, 沿 $d^{(k)}$ 作一维搜索, 得到下一个点 $x^{(k+1)}$, 即

$$\min f(x^{(k)} + \lambda d^{(k)}) = f(x^{(k)} + \lambda_k d^{(k)})$$

$$x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$$

可通过求解下列一维搜索问题来确定 λ_k

$$(3) \quad \begin{cases} \min f(x^{(k)} + \lambda d^{(k)}) \\ s.t. \quad A(x^{(k)} + \lambda d^{(k)}) \geq b \\ \quad \quad E(x^{(k)} + \lambda d^{(k)}) = e \\ \quad \quad \lambda \geq 0 \end{cases}$$

对问题(3)化简

(1) $\because d^{(k)}$ 是可行方向, $x^{(k)}$ 是可行解 $\therefore Ed^{(k)} = 0$,

$Ex^{(k)} = e$, 因此问题(3)第2个约束是多余的。

(2)考虑第一个约束。在点 $x^{(k)}$ 处, 假设

$$A_1x^{(k)} = b_1, \quad A_2x^{(k)} > b_2$$

即有
$$\begin{pmatrix} A_1x^{(k)} + \lambda A_1d^{(k)} \\ A_2x^{(k)} + \lambda A_2d^{(k)} \end{pmatrix} \geq \begin{pmatrix} b_1 \\ b_2 \end{pmatrix}$$

$$\begin{cases} \min f(x^{(k)} + \lambda d^{(k)}) \\ \text{s.t.} \quad A(x^{(k)} + \lambda d^{(k)}) \geq b \\ \quad \quad E(x^{(k)} + \lambda d^{(k)}) = e \\ \quad \quad \lambda \geq 0 \end{cases}$$

$\because d^{(k)}$ 是可行方向, $\therefore A_1d^{(k)} \geq 0, \lambda \geq 0$

$$\Rightarrow A_1x^{(k)} + \lambda A_1d^{(k)} \geq b_1$$

\therefore 第一个约束可简化为

$$A_2x^{(k)} + \lambda A_2d^{(k)} \geq b_2。$$

$$\text{问题(3)} \quad \left\{ \begin{array}{l} \min f(x^{(k)} + \lambda d^{(k)}) \\ s.t. \quad A(x^{(k)} + \lambda d^{(k)}) \geq b \\ \quad \quad E(x^{(k)} + \lambda d^{(k)}) = e \\ \quad \quad \lambda \geq 0 \end{array} \right. \quad \text{等价于}$$

$$(4) \quad \left\{ \begin{array}{l} \min f(x^{(k)} + \lambda d^{(k)}) \\ s.t. \quad A_2 x^{(k)} + \lambda A_2 d^{(k)} \geq b_2 \\ \quad \quad \lambda \geq 0 \end{array} \right.$$

确定问题(4)的可行域

$A_2 x^{(k)} + \lambda A_2 d^{(k)} \geq b_2$ 移项, 得

$$\lambda A_2 d^{(k)} \geq b_2 - A_2 x^{(k)}$$

令 $\hat{b} = b_2 - A_2 x^{(k)}$, $\hat{d} = A_2 d^{(k)}$,

则(4)的约束可写成
$$\begin{cases} \lambda \hat{d} \geq \hat{b} \\ \lambda \geq 0 \end{cases}$$

$$\begin{cases} \min f(x^{(k)} + \lambda d^{(k)}) \\ s.t. \\ A_2 x^{(k)} + \lambda A_2 d^{(k)} \geq b_2 \\ \lambda \geq 0 \end{cases}$$

$$\therefore \lambda_{\max} = \begin{cases} \min \left\{ \frac{\hat{b}_i}{\hat{d}_i} \mid \hat{d}_i < 0 \right\} & \hat{d} \not\geq 0 \\ \infty & \hat{d} \geq 0 \end{cases}$$

$$\text{问题(4)} \quad \begin{cases} \min f(x^{(k)} + \lambda d^{(k)}) \\ s.t. \quad A_2 x^{(k)} + \lambda A_2 d^{(k)} \geq b_2 \\ \lambda \geq 0 \end{cases} \text{等价于}$$

$$(5) \quad \begin{cases} \min f(x^{(k)} + \lambda d^{(k)}) \\ s.t. \quad 0 \leq \lambda \leq \lambda_{\max} \end{cases}$$

$$\text{其中 } \lambda_{\max} = \begin{cases} \min \left\{ \frac{\hat{b}_i}{\hat{d}_i} \mid \hat{d}_i < 0 \right\} & \hat{d} \not\geq 0 \\ \infty & \hat{d} \geq 0 \end{cases}$$

问题(1)初始可行解的确定

引入人工变量(向量) ξ 和 η , 解辅助线性规划问题:

$$\left\{ \begin{array}{l} \min \left(\sum_{i=1}^m \xi_i + \sum_{i=1}^l \eta_i \right) \\ s.t. \quad Ax + \xi \geq b \\ \quad \quad Ex + \eta = e \\ \quad \quad \xi, \eta \geq 0 \end{array} \right.$$

如果有最优解 $(\bar{x}, \bar{\xi}, \bar{\eta}) = (\bar{x}, 0, 0)$, 则 \bar{x} 为(1)的一个可行解。

步骤

1. 给定初始可行点 $x^{(1)}$, 置 $k = 1$ 。

2. 在点 $x^{(k)}$ 处把 A 和 b 分解成

$$\begin{bmatrix} A_1 \\ A_2 \end{bmatrix} \text{ 和 } \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$$

使得 $A_1 x^{(k)} = b_1$, $A_2 x^{(k)} > b_2$ 。计算 $\nabla f(x^{(k)})$ 。

3. 求解线性规划问题

$$\begin{cases} \min \nabla f(x^{(k)})^T d \\ s.t. \quad A_1 d \geq 0 \\ \quad \quad Ed = 0 \\ \quad \quad -1 \leq d_i \leq 1 \quad i = 1, 2, \dots, n \end{cases}$$

得到最优解 $d^{(k)}$ 。

4.如果 $\nabla f(x^{(k)})^T d^{(k)} = 0$, 则停止计算, $x^{(k)}$ 为 *KKT*点; 否则, 转5。

5.计算 $\hat{b} = b_2 - A_2 x^{(k)}$, $\hat{d} = A_2 d^{(k)}$ 。

6.若 $\hat{d} \geq 0$, 则从 $x^{(k)}$ 出发, 沿 $d^{(k)}$ 进行一维搜索

$$\min f(x^{(k)} + \lambda d^{(k)}) = f(x^{(k)} + \lambda_k d^{(k)})$$

令 $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$, 转8; 否则, 转7。

7. 计算 $\lambda_{\max} = \min \left\{ \frac{\hat{b}_i}{\hat{d}_i} \mid \hat{d}_i < 0 \right\}$, 求解

$$\min f(x^{(k)} + \lambda d^{(k)})$$

$$s.t. \quad 0 \leq \lambda \leq \lambda_{\max}$$


得最优解 λ_k , 令 $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$, 转8。

8. 确定 $x^{(k+1)}$ 的起作用约束, 修改 A_1, A_2 及 b_1, b_2 , 置 $k := k + 1$, 返回2。

用Zoutendijk可行方向法求解

$$\left\{ \begin{array}{l} \min f(x) = 2x_1^2 + 2x_2^2 - 2x_1x_2 - 4x_1 - 6x_2 \\ s.t. \quad -x_1 - x_2 \geq -2 \\ \quad \quad -x_1 - 5x_2 \geq -5 \\ \quad \quad x_1 \geq 0 \\ \quad \quad x_2 \geq 0 \end{array} \right.$$

$$A = \begin{pmatrix} -1 & -1 \\ -1 & -5 \\ 1 & 0 \\ 0 & 1 \end{pmatrix}$$



取 $x^{(1)} = (0, 0)^T$,

$$\nabla f(x) = (4x_1 - 2x_2 - 4, 4x_2 - 2x_1 - 6)^T$$


第一次迭代

$$A_1 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, A_2 = \begin{pmatrix} -1 & -1 \\ -1 & -5 \end{pmatrix}, b_1 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, b_2 = \begin{pmatrix} -2 \\ -5 \end{pmatrix},$$

$$\nabla f(x^{(1)}) = (-4, -6)^T$$


求搜索方向 $d^{(1)}$ ，即解线性规划问题

$$\begin{cases} \min -4d_1 - 6d_2 \\ s.t. \quad d_1 \geq 0 \\ \quad \quad d_2 \geq 0 \\ \quad \quad -1 \leq d_i \leq 1 \quad i=1,2 \end{cases}$$



用单纯形法求解，得最优解 $d^{(1)} = (1,1)^T$

图像无法显示此图像。




第二次迭代

$$A_1 = (-1, -5), A_2 = \begin{pmatrix} -1 & -1 \\ 1 & 0 \\ 0 & 1 \end{pmatrix}, b_1 = (-5), b_2 = \begin{pmatrix} -2 \\ 0 \\ 0 \end{pmatrix},$$

$$\nabla f(x^{(2)}) = \left(-\frac{7}{3}, -\frac{13}{3}\right)^T$$

求搜索方向 $d^{(2)}$, 即解线性规划问题


$$\begin{cases} \min -\frac{7}{3}d_1 - \frac{13}{3}d_2 \\ s.t. \quad -d_1 - 5d_2 \geq 0 \\ \quad \quad -1 \leq d_i \leq 1 \quad i = 1, 2 \end{cases} \Rightarrow \text{得最优解 } d^{(2)} = \left(1, -\frac{1}{5}\right)^T$$



$$\nabla f(x^{(2)})^T d^{(2)} = -\frac{22}{15} \neq 0,$$

$$\text{令 } \hat{b} = b_2 - A_2 x^{(2)} = \left(-\frac{1}{3}, -\frac{5}{6}, -\frac{5}{6}\right)^T, \quad \hat{d} = A_2 d^{(2)} = \left(-\frac{4}{5}, 1, -\frac{1}{5}\right)$$

$$\lambda_{\max} = \min \left\{ \frac{-1/3}{-4/5}, \frac{-5/6}{-1/5} \right\} = \frac{5}{12}$$



$$\text{求解一维搜索问题} \quad \begin{cases} \min f(x^{(1)} + \lambda d^{(1)}) = \frac{62}{25} \lambda^2 - \frac{22}{15} \lambda - \frac{125}{18} \\ s.t. \quad 0 \leq \lambda \leq \frac{5}{12} \end{cases}$$

$$\text{得 } \lambda_2 = \frac{55}{186} \Rightarrow x^{(3)} = x^{(2)} + \lambda_2 d^{(2)} = \left(\frac{35}{31}, \frac{24}{31}\right)^T.$$


第三次 迭代

$$A_1 = (-1, -5), A_2 = \begin{pmatrix} -1 & -1 \\ 1 & 0 \\ 0 & 1 \end{pmatrix}, b_1 = (-5), b_2 = \begin{pmatrix} -2 \\ 0 \\ 0 \end{pmatrix},$$

$$\nabla f(x^{(3)}) = \left(-\frac{32}{31}, -\frac{160}{31} \right)^T$$

求搜索方向 $d^{(3)}$, 即解线性规划问题

$$\begin{cases} \min -\frac{32}{31}d_1 - \frac{160}{31}d_2 \\ s.t. \quad -d_1 - 5d_2 \geq 0 \\ \quad \quad -1 \leq d_i \leq 1 \quad i=1,2 \end{cases} \Rightarrow \text{得最优解 } d^{(3)} = \left(1, -\frac{1}{5} \right)^T$$



$\nabla f(x^{(3)})^T d^{(3)} = 0$, 迭代停止。 ,

得KKT点 $x^{(3)} = \left(\frac{35}{31}, \frac{24}{31} \right)^T = x^*$.

由于 $f(x)$ 是凸函数, 原问题为凸规划,
所以 x^* 为最优解。

二.非线性约束的情形

$$(A) \quad \begin{cases} \min f(x) \\ s.t. \quad g_i(x) \geq 0, i = 1, 2, \dots, m \end{cases}$$

其中 $f(x), g_i(x)$ 均为可微函数。

问题:

如何求可行下降方向?

定理: 设 x 是问题 (A) 的可行解, $I = \{i \mid g_i(x) = 0\}$ 是在 x 处起作用约束下标集, 又设 $f(x)$, $g_i(x)(i \in I)$ 在 x 处可微, $g_i(x)(i \notin I)$ 在 x 处连续, 如果 $\nabla f(x)^T d < 0$, $\nabla g_i(x)^T d > 0(i \in I)$, 则 d 是可行下降方向。

证明: $\because \nabla f(x)^T d < 0, \therefore d$ 为下降方向。

$\because \nabla g_i(x)^T d > 0(i \in I)$, 即 $-\nabla g_i(x)^T d < 0(i \in I)$

$\therefore \exists \delta_1 > 0$, 使得对 $\forall \lambda \in (0, \delta_1)$, 当 $i \in I$ 时, 有

$-g_i(x + \lambda d) < -g_i(x) = 0 \Rightarrow g_i(x + \lambda d) > 0$ 。

当 $i \notin I$ 时, 有 $g_i(x) > 0, \because g_i(x)$ 连续,

$\therefore \exists \delta_2 > 0$, 对 $\forall \lambda \in (0, \delta_2)$, 有 $g_i(x + \lambda d) \geq 0$ 。

取 $\delta = \min(\delta_1, \delta_2)$, 则当 $\lambda \in (0, \delta)$ 时, 有

$g_i(x + \lambda d) \geq 0 \Rightarrow d$ 为可行方向。

求可行点 x 处的下降可行方向

$$(B) \quad \begin{cases} \min z \\ s.t. \quad \nabla f(x)^T d - z \leq 0 \\ \quad \quad \nabla g_i(x)^T d + z \geq 0, \quad i \in I \\ \quad \quad -1 \leq d_i \leq 1, \quad i = 1, 2, \dots, n \end{cases}$$

设问题的最优解为 (\bar{z}, \bar{d}) , 若 $\bar{z} < 0$, 则 \bar{d} 为在 x 处的可行下降方向。

定理： 设 x 是问题 (A) 的可行解， $I = \{i \mid g_i(x) = 0\}$ ，
则 x 是Fritz John点的充要条件是问题 (B) 的目标函数最优值 $= 0$ 。

证明： 问题 (B) 的目标函数最优值 $= 0$ 的
充要条件是不等式组

$$(C) \quad \begin{cases} \nabla f(x)^T d < 0 \\ \nabla g_i(x)^T d > 0 \quad i \in I \end{cases}$$

无解。

$$\begin{cases} \min z \\ s.t. \quad \nabla f(x)^T d - z \leq 0 \\ \nabla g_i(x)^T d + z \geq 0, i \in I \\ -1 \leq d_i \leq 1, \\ i = 1, 2, \dots, n \end{cases}$$

设问题 (B) 的目标函数最优值为 \bar{z} 。

" \Rightarrow " 设 $\bar{z} = 0$, 而系统(C)有解 \bar{d} , 即

$$\nabla f(x)^T \bar{d} < 0 \text{ 且 } \nabla g_i(x)^T \bar{d} > 0 \quad \forall i \in I$$

显然对任意 $\lambda > 0$, $\lambda \bar{d}$ 也是系统(C)的解

$$\text{即 } \nabla f(x)^T \lambda \bar{d} < 0 \text{ 且 } \nabla g_i(x)^T \lambda \bar{d} > 0 \quad \forall i \in I,$$

$$\text{令 } -1 \leq \lambda \bar{d}_i \leq 1, i = 1, 2, \dots, n$$

$$\text{设 } \hat{z} = \max \{ \nabla f(x)^T \lambda \bar{d}, -\nabla g_i(x)^T \lambda \bar{d}, \forall i \in I \}$$

显然 $\hat{z} < 0$, 且有

$$\nabla f(x)^T \lambda \bar{d} \leq \hat{z}, \quad -\nabla g_i(x)^T \lambda \bar{d} \leq \hat{z}, \quad \forall i \in I$$

$$\Rightarrow \begin{cases} \nabla f(x)^T \lambda \bar{d} - \hat{z} \leq 0 \\ \nabla g_i(x)^T \lambda \bar{d} + \hat{z} \geq 0, \forall i \in I \\ -1 \leq \lambda \bar{d}_i \leq 1, i = 1, 2, \dots, n \end{cases}$$

$\therefore (\hat{z}, \lambda \bar{d})$ 是问题(B)的一个可行解,

$\therefore \bar{z} \leq \hat{z} < 0$, 与 $\bar{z} = 0$ 矛盾。

$$\begin{cases} \nabla f(x)^T d < 0 \\ \nabla g_i(x)^T d > 0 \quad i \in I \end{cases}$$

$$\begin{cases} \min z \\ \text{s.t. } \nabla f(x)^T d - z \leq 0 \\ \nabla g_i(x)^T d + z \geq 0, i \in I \\ -1 \leq d_i \leq 1, \\ i = 1, 2, \dots, n \end{cases}$$

" \Leftarrow " 设系统(C)无解, 即对任意的 d , 有

$$\begin{cases} \nabla f(x)^T d < 0 \\ \nabla f(x)^T d \geq 0 \text{ 或 } \nabla g_i(x)^T d \leq 0 (i \in I) \\ \nabla g_i(x)^T d > 0 (i \in I) \end{cases}$$

不妨设 $\nabla g_i(x)^T d \leq 0 (i \in I) \Rightarrow \bar{z} \geq -\nabla g_i(x)^T d \geq 0$

又零向量是问题(B)的一个可行解, $\therefore \bar{z} \leq 0 \Rightarrow \bar{z} = 0$

$\therefore \bar{z} = 0 \Leftrightarrow \begin{cases} \nabla f(x)^T d < 0 \\ \nabla g_i(x)^T d > 0 (i \in I) \end{cases}$ 无解

$\Leftrightarrow \begin{cases} \nabla f(x)^T d < 0 \\ -\nabla g_i(x)^T d < 0 (i \in I) \end{cases}$ 无解

$$\begin{cases} \min z \\ s.t. \quad \nabla f(x)^T d - z \leq 0 \\ \nabla g_i(x)^T d + z \geq 0, i \in I \\ -1 \leq d_i \leq 1, \\ i = 1, 2, \dots, n \end{cases}$$

\Leftrightarrow 存在不全为0的数 $w_0, w_i \geq 0 (i \in I)$ 使得

$$w_0 \nabla f(x) - \sum_{i \in I} w_i \nabla g_i(x) = 0$$

即 x 是Fritz John点。

为确定步长 λ_k ，仍需要求解一维搜索问题

$$\min f(x^{(k)} + \lambda d^{(k)})$$

$$s.t. \quad 0 \leq \lambda \leq \lambda_{\max}$$

其中

$$\lambda_{\max} = \sup \left\{ \lambda \mid g_i(x^{(k)} + \lambda d^{(k)}) \geq 0, i = 1, 2, \dots, m \right\}.$$

步骤

1. 给定初始可行点 $x^{(1)}$, 允许误差 $\varepsilon > 0$, 置 $k = 1$ 。

2. 令 $I = \{i \mid g_i(x^{(k)}) = 0\}$ 。求解线性规划问题

$$\begin{cases} \min z \\ s.t. \quad \nabla f(x^{(k)})^T d - z \leq 0 \\ \quad \quad \nabla g_i(x^{(k)})^T d + z \geq 0 \quad i \in I \\ \quad \quad -1 \leq d_i \leq 1 \quad i = 1, 2, \dots, n \end{cases}$$

得到最优解 $(z_k, d^{(k)})$ 。若 $|z_k| \leq \varepsilon$, 则停止计算,
 $x^{(k)}$ 是Fritz John点; 否则, 转3。

3.求解一维搜索问题

$$\begin{aligned} \min & f(x^{(k)} + \lambda d^{(k)}) \\ \text{s.t.} \quad & 0 \leq \lambda \leq \lambda_{\max} \end{aligned}$$

其中

$$\lambda_{\max} = \sup \left\{ \lambda \mid g_i(x^{(k)} + \lambda d^{(k)}) \geq 0, i = 1, 2, \dots, m \right\}$$

得最优解 λ_k 。

4.令 $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$, 置 $k := k + 1$, 返回2。

用**Zoutendijk**可行方向法求解


$$\min f(x) = 2x_1^2 + 2x_2^2 - 2x_1x_2 - 4x_1 - 6x_2$$

$$s.t. \quad -x_1 - 5x_2 \geq -5$$

$$-2x_1^2 + x_2 \geq 0$$

$$x_1 \geq 0$$

$$x_2 \geq 0$$



$$x^{(1)} = (0, 0.75)^T$$

$$\nabla f(x) = (4x_1 - 2x_2 - 4, 4x_2 - 2x_1 - 6)^T$$


第一次迭代

$$\nabla f(x^{(1)}) = (-5.5, -3)^T, I = \{3\}, \nabla g_3(x^{(1)}) = (1, 0)^T$$

$$\text{求解} \begin{cases} \min z \\ s.t. \quad -5.5d_1 - 3d_2 - z \leq 0 \\ d_1 + z \geq 0 \\ -1 \leq d_i \leq 1, i = 1, 2 \end{cases}$$

得最优解 $d^{(1)} = (1, -1)^T, z_{\min} = -1$.

进行一维搜索



$$\text{一维搜索: } x^{(1)} + \lambda d^{(1)} = (\lambda, 0.75 - \lambda)^T$$

$$f(x^{(1)} + \lambda d^{(1)}) = 6\lambda^2 - 2.5\lambda - 3.375$$

$$\lambda_{\max} = \sup \left\{ \lambda \left| \begin{array}{l} -\lambda - 5(0.75 - \lambda) \geq -5 \\ -2\lambda^2 + 0.75 - \lambda \geq 0 \\ \lambda \geq 0 \\ 0.75 - \lambda \geq 0 \end{array} \right. \right\}$$

$$\Rightarrow \lambda_{\max} = \frac{-1 + \sqrt{7}}{4} \approx 0.4114$$

$$\text{求解 } \min 6\lambda^2 - 2.5\lambda - 3.375$$

$$s.t. \ 0 \leq \lambda \leq 0.4114$$

$$\text{得 } \lambda_1 = 0.2083 \Rightarrow x^{(2)} = x^{(1)} + \lambda_1 d^{(1)} = (0.2083, 0.5417)^T.$$

继续进行迭代，经过4次迭代后，得

$$x^{(5)} = (0.6302, 0.8740)^T,$$

$$\nabla f(x^{(5)}) = (-3.2272, -3.7644)^T, I = \emptyset.$$

$$\text{求解} \begin{cases} \min z \\ s.t. \quad -3.2272d_1 - 3.7644d_2 - z \leq 0 \\ \quad \quad -1 \leq d_i \leq 1, \quad i = 1, 2 \end{cases}$$

$$\text{得} z = 0, f(x^{(5)}) = -6.5403$$

本题最优解为：

$$x^* = (0.658872, 0.868224)^T$$

$$f(x^*) = -6.613086$$

Zoutendijk算法的收敛问题

Zoutendijk算法映射 $A=MD$ ，其中 D 是确定方向的映射， M 是一维搜索。

结论： D 和 M 不一定是闭映射。

$$\min -2x_1 - x_2$$

$$s.t. \quad -x_1 - x_2 + 2 \geq 0$$


$$x_1, x_2 \geq 0$$

考虑序列 $\{x^{(k)}\}$, 其中 $x^{(k)} = \left(0, 2 - \frac{1}{k}\right)^T$

求 $x^{(k)}$ 的下降可行方向


$$\begin{cases} \min -2d_1 - d_2 \\ s.t. \quad 0 \leq d_1 \leq 1 \\ \quad \quad -1 \leq d_2 \leq 1 \end{cases} \Rightarrow d^{(k)} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$x^{(k)} = \left(0, 2 - \frac{1}{k}\right)^T \rightarrow (0, 2)^T = \hat{x}$$



求 \hat{x} 的下降可行方向，即求 $D(\hat{x})$.

$$\begin{cases} \min -2d_1 - d_2 \\ s.t. \quad -d_1 - d_2 \geq 0 \\ \quad \quad 0 \leq d_1 \leq 1 \\ \quad \quad -1 \leq d_2 \leq 1 \end{cases} \Rightarrow \hat{d} = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$



$$D(\hat{x}) = \left\{ \begin{pmatrix} \hat{x} \\ \hat{d} \end{pmatrix} \right\}$$

当 $x^{(k)} \rightarrow \hat{x}$ 时, $(x^{(k)}, d^{(k)}) \rightarrow (\hat{x}, d)$, 其中 $d = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$.

显然 $(\hat{x}, d) \notin D(\hat{x})$, 因此 D 在 \hat{x} 处不是闭的.

Topkis-Veinott修正的可行方向法

改进措施: x 处的下降可行方向 d 由如下线性规划问题来确定.

$$\left\{ \begin{array}{l} \min z \\ s.t. \quad \nabla f(x)^T d - z \leq 0 \\ \quad \quad \nabla g_i(x)^T d + z \geq -g_i(x) \quad i = 1, 2, \dots, m \\ \quad \quad -1 \leq d_i \leq 1 \quad i = 1, 2, \dots, n \end{array} \right.$$

用**Topkis-Veinott**修正可行方向法求解

$$\min f(x) = 2x_1^2 + 2x_2^2 - 2x_1x_2 - 4x_1 - 6x_2$$

$$s.t. \quad -x_1 - 5x_2 \geq -5$$

$$-2x_1^2 + x_2 \geq 0$$

$$x_1 \geq 0$$


$$x_2 \geq 0$$

$$x^{(1)} = (0, 0.75)^T$$

$$\nabla f(x) = (4x_1 - 2x_2 - 4, 4x_2 - 2x_1 - 6)^T$$

$$\nabla g_1(x) = (-1, -5)^T, \nabla g_2(x) = (-4x_1, 1)^T$$


$$\nabla g_3(x) = (1, 0)^T, \nabla g_4(x) = (0, 1)^T$$



第一次迭代

$\nabla f(x^{(1)}) = (-5.5, -3)^T$, 求解

$$\left\{ \begin{array}{l} \min z \\ s.t. \quad -5.5d_1 - 3d_2 - z \leq 0 \\ \quad \quad -d_1 - 5d_2 + z \geq -1.25 \\ \quad \quad d_2 + z \geq -0.75 \\ \quad \quad d_1 + z \geq 0 \\ \quad \quad d_2 + z \geq -0.75 \\ \quad \quad -1 \leq d_i \leq 1, i = 1, 2 \end{array} \right.$$



得最优解 $d^{(1)} = (0.7143, -0.03571)^T$, $z_{\min} = -0.7143$.

进行一维搜索

一维搜索: $x^{(1)} + \lambda d^{(1)} = (0.7143\lambda, 0.75 - 0.03571\lambda)^T$

$$f(x^{(1)} + \lambda d^{(1)}) = 1.074\lambda^2 - 3.82152\lambda - 3.375$$

$$\lambda_{\max} = \sup \left\{ \lambda \left| \begin{array}{l} -\lambda - 5(0.75 - \lambda) \geq -5 \\ -2\lambda^2 + 0.75 - \lambda \geq 0 \\ \lambda \geq 0 \\ 0.75 - \lambda \geq 0 \end{array} \right. \right\}$$

$$\Rightarrow \lambda_{\max} = \frac{-1 + \sqrt{7}}{4} \approx 0.4114$$

$$\text{求解 } \min 1.074\lambda^2 - 3.82152\lambda - 3.375$$

$$s.t. \ 0 \leq \lambda \leq 0.4114$$

$$\text{得 } \lambda_1 = 0.4114 \Rightarrow x^{(2)} = x^{(1)} + \lambda_1 d^{(1)} = (0.29, 0.7353)^T.$$

继续进行迭代，经过5次迭代后，得

$$x^{(6)} = (0.6548, 0.8575)^T,$$

$$f(x^{(6)}) = -6.5590$$

本题最优解为：

$$x^* = (0.658872, 0.868224)^T$$

$$f(x^*) = -6.613086$$

Rosen梯度投影法

$$\begin{cases} \min f(x) \\ s.t. \quad Ax \geq b \\ \quad \quad Ex = e \end{cases} \quad (1)$$

其中 $f(x)$ 可微, $A_{m \times n}$, $E_{l \times n}$, $x_{n \times 1}$, $b_{m \times 1}$, $e_{l \times 1}$

$S = \{x \mid Ax \geq b, Ex = e\}$ --- 可行域

基本思想: 当迭代点在可行域内部时,沿迭代点的负梯度方向搜索;当迭代点达到约束区域的边界上时,用起作用约束系数矩阵的行向量生成一个子空间,沿负梯度方向在该子空间的正交补中的投影方向搜索。

设 B 是一个 $m \times n$ 阶矩阵, 且 $r(B) = m$.

设 B 的 m 个行向量为 $\alpha_1^T, \alpha_2^T, \dots, \alpha_m^T$, 由 B 的 m 个行向量生成的子空间记为 V_B , 即

$$V_B = \text{span}(\alpha_1^T, \alpha_2^T, \dots, \alpha_m^T)$$

V_B 的正交子空间记为 V_B^\perp , 则

$$V_B^\perp = \{x \mid Bx = 0\}.$$

结论: $E^n = V_B \oplus V_B^\perp$

定义： 设 U 是 E^n 的子空间，对 $\forall x \in E^n$ ，可唯一的分解为

$$x = y + z$$

其中 $y \in U, z \in U^\perp$ 。

由 E^n 到 U 的这种映射记为 Q ，即 $Qx = y$ ，称 Q 为由 E^n 到 U 的正交投影矩阵。由 E^n 到 U^\perp 的这种映射记为 P ，即 $Px = z$ ，称 P 为由 E^n 到 U^\perp 的正交投影矩阵。

定理： 设 $\alpha_1, \alpha_2, \dots, \alpha_r$ 是子空间 U 的一组基，记

$$M = \begin{bmatrix} \alpha_1^T \\ \alpha_2^T \\ \vdots \\ \alpha_r^T \end{bmatrix}_{r \times n}$$

则

(1)由 E^n 到 U 的正交投影矩阵 Q 可表示为

$$Q = M^T (MM^T)^{-1} M。$$

(2)由 E^n 到 U^\perp 的正交投影矩阵 P 可表示为

$$P = I - M^T (MM^T)^{-1} M。$$

证明: (1) $\forall x \in E^n$ 可唯一分解为

$$x = y + z \quad y \in U, z \in U^\perp$$

则 $y = k_1 \alpha_1 + k_2 \alpha_2 + \cdots + k_r \alpha_r$, 且 $\alpha_i^T z = 0$

记 $K = (k_1, k_2, \cdots, k_r)^T$, 则 $y = M^T K$

$$\Rightarrow x = M^T K + z$$

两边左乘 M , 得 $Mx = MM^T K + Mz$

$$\because \alpha_i^T z = 0 (i = 1, 2, \cdots, r) \quad \therefore Mz = 0$$

$$\therefore Mx = MM^T K$$

$$\because MM^T \text{可逆} \therefore K = (MM^T)^{-1} Mx$$

$$\because y = Qx \quad \therefore Qx = M^T (MM^T)^{-1} Mx \Rightarrow Q = M^T (MM^T)^{-1} M$$

$$M = \begin{bmatrix} \alpha_1^T \\ \alpha_2^T \\ \vdots \\ \alpha_r^T \end{bmatrix}_{r \times n}$$

(2) 因为 P 是 E^n 到 U^\perp 的正交投影矩阵

所以对于 $x = y + z$ $y \in U, z \in U^\perp$

有 $Px = z \Rightarrow Ix = Qx + Px$

$\Rightarrow I = P + Q$

$$Q = M^T (MM^T)^{-1} M$$

$$P = I - M^T (MM^T)^{-1} M$$

推论1: 若 Q 是正交投影矩阵, 则 $Q^T = Q$, $QQ = Q$.

推论2: 若 Q 是正交投影矩阵, 则 Q 是半正定的.

定理1 设 x 是问题(1)的可行解, 在点 x 处, 有 $A_1x = b_1$, $A_2x > b_2$, 其中

$$A = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix} \quad b = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$$

$$\begin{cases} \min f(x) \\ s.t. \quad Ax \geq b \\ \quad \quad Ex = e \end{cases} \quad (1)$$

又设 $M = \begin{bmatrix} A_1 \\ E \end{bmatrix}$ 为满秩矩阵, 令

$$P = I - M^T (MM^T)^{-1} M$$

若 $P\nabla f(x) \neq 0$, 令 $d = -P\nabla f(x)$, 则 d 为下降可行方向。

证明： $\because P$ 为正交投影矩阵，且 $P\nabla f(x) \neq 0$

$$\therefore \nabla f(x)^T d = -\nabla f(x)^T P \nabla f(x)$$

$$= -\|P \nabla f(x)\|^2 < 0$$

所以 d 为下降方向。又

$$M = \begin{bmatrix} A_1 \\ E \end{bmatrix}$$

$$Md = -MP \nabla f(x)$$

$$= -M \left(I - M^T (MM^T)^{-1} M \right) \nabla f(x)$$

$$= (-M + M) \nabla f(x) = 0$$

即 $A_1 d = 0, Ed = 0 \Rightarrow d$ 是可行方向。

定理2: 设 x 是问题(1)的可行解, 在点 x 处, 有 $A_1x = b_1$,
 $A_2x > b_2$, 其中

$$A = \begin{bmatrix} A_1 \\ A_2 \end{bmatrix} \quad b = \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$$

又设 $M = \begin{bmatrix} A_1 \\ E \end{bmatrix}$ 为满秩矩阵, 令

$$P = I - M^T (MM^T)^{-1} M$$

$$W = (MM^T)^{-1} M \nabla f(x) = \begin{bmatrix} u \\ v \end{bmatrix}$$

其中 u 和 v 分别对应于 A_1 和 E 。设 $P \nabla f(x) = 0$, 则

1. 若 $u \geq 0$, 则 x 为 KKT 点;

2. 如果 u 中含有负分量, 不妨设 $u_j < 0$, 这时从 A_1 中去掉 u_j 对应的行, 得到 \hat{A}_1 。令

$$\hat{M} = \begin{bmatrix} \hat{A}_1 \\ E \end{bmatrix} \quad \hat{P} = I - \hat{M}^T (\hat{M} \hat{M}^T)^{-1} \hat{M}$$

$$d = -\hat{P} \nabla f(x)$$

则 d 为 x 处的下降可行方向。

$$W = (MM^T)^{-1} M \nabla f(x) = \begin{bmatrix} u \\ v \end{bmatrix}$$

证明：(1) 设 $u \geq 0$ ，则

$$0 = P \nabla f(x) = [I - M^T (M M^T)^{-1} M] \nabla f(x)$$

$$= \nabla f(x) - M^T (M M^T)^{-1} M \nabla f(x)$$

$$= \nabla f(x) - \begin{pmatrix} A_1^T & E^T \end{pmatrix} \begin{pmatrix} u \\ v \end{pmatrix}$$

$$M = \begin{bmatrix} A_1 \\ E \end{bmatrix}$$

$$= \nabla f(x) - A_1^T u - E^T v$$

因为 $u \geq 0$ ，所以 x 为 KKT 点。

$$W = (M M^T)^{-1} M \nabla f(x) = \begin{bmatrix} u \\ v \end{bmatrix}$$

2. 如果 u 中含有负分量, 不妨设 $u_j < 0$, 这时从 A_1 中去掉 u_j 对应的行, 得到 \hat{A}_1 。令

$$\hat{M} = \begin{bmatrix} \hat{A}_1 \\ E \end{bmatrix} \quad \hat{P} = I - \hat{M}^T \left(\hat{M} \hat{M}^T \right)^{-1} \hat{M}$$

$$d = -\hat{P} \nabla f(x)$$

则 d 为 x 处的下降可行方向。

$$W = \left(M M^T \right)^{-1} M \nabla f(x) = \begin{bmatrix} u \\ v \end{bmatrix}$$

(2) 设 $u_j < 0$ 。若 $\hat{P}\nabla f(x) = 0$, 则有

$$\begin{aligned} 0 &= \hat{P}\nabla f(x) = (I - \hat{M}^T (\hat{M}\hat{M}^T)^{-1} \hat{M})\nabla f(x) \\ &= \nabla f(x) - \hat{M}^T \hat{W} \end{aligned} \quad (a)$$

其中 $\hat{W} = (\hat{M}\hat{M}^T)^{-1} \hat{M}\nabla f(x)$. 设 A_1 中对应 u_j 的行向量为 r_j ,

$$\because A_1^T u + E^T v = \hat{A}_1^T \hat{u} + u_j r_j^T + E^T v = \hat{M}^T \bar{W} + u_j r_j^T$$

$$\begin{aligned} \therefore 0 &= \nabla f(x) - A_1^T u - E^T v \\ &= \nabla f(x) - \hat{M}^T \bar{W} - u_j r_j^T \end{aligned} \quad (b)$$

$$\Rightarrow 0 = \hat{M}^T (\bar{W} - \hat{W}) + u_j r_j^T$$

$\Rightarrow M$ 的行向量组线性相关, 与 M 行满秩矛盾。

因此必有 $\hat{P}\nabla f(x) \neq 0$ 。

由于 \hat{P} 为投影矩阵, $\hat{P}\nabla f(x) \neq 0$, 则

$$\nabla f(x)^T d = -\nabla f(x)^T \hat{P}\nabla f(x)$$

$$= -\|\hat{P}\nabla f(x)\|^2 < 0$$

$\therefore d = -\hat{P}\nabla f(x)$ 是下降方向。

$$\text{由于 } \hat{M}d = -\hat{M}\hat{P}\nabla f(x)$$

$$= -\hat{M}(I - \hat{M}^T(\hat{M}\hat{M}^T)^{-1}\hat{M})\nabla f(x)$$

$$= -(\hat{M} - \hat{M})\nabla f(x) = 0$$

$$\text{因此 } \hat{A}_1 d = 0 \quad Ed = 0$$

(b)两边左乘 $r_j\hat{P}$, 得到

$$0 = \nabla f(x) - \hat{M}^T \bar{W} - u_j r_j^T \quad (b)$$

$$r_j \hat{P} \nabla f(x) - r_j \hat{P} \hat{M}^T \bar{W} - u_j r_j \hat{P} r_j^T = 0$$

$$\text{因为 } \hat{P} \hat{M}^T = \left(I - \hat{M}^T (\hat{M} \hat{M}^T)^{-1} \hat{M} \right) \hat{M}^T = 0,$$

$$d = -\hat{P} \nabla f(x)$$

$$\Rightarrow r_j d + u_j r_j \hat{P} r_j^T = 0$$

由于 \hat{P} 半正定, $r_j \hat{P} r_j^T \geq 0$ 及 $u_j < 0$, 因此

$$r_j d = -u_j r_j \hat{P} r_j^T \geq 0$$

因此有 $A_1 d \geq 0, \quad E d = 0$

$\Rightarrow d$ 为可行方向。

$\Rightarrow d$ 为 x 处的下降可行方向。

步骤

1. 给定初始可行点 $x^{(1)}$, 置 $k = 1$ 。

2. 在点 $x^{(k)}$ 处把 A 和 b 分解成

$$\begin{bmatrix} A_1 \\ A_2 \end{bmatrix} \text{ 和 } \begin{bmatrix} b_1 \\ b_2 \end{bmatrix}$$

使得 $A_1 x^{(k)} = b_1$, $A_2 x^{(k)} > b_2$ 。

3. 令 $M = \begin{bmatrix} A_1 \\ E \end{bmatrix}$, 如果 M 是空的, 则令 $P = I$; 否则令

$$P = I - M^T (MM^T)^{-1} M。$$

4.令 $d^{(k)} = -P\nabla f(x^{(k)})$, 若 $d^{(k)} \neq 0$, 则转6;

否则, 转5。

5.若 M 是空的, 则停止计算, 得 $x^{(k)}$; 否则令

$$W = (MM^T)^{-1} M\nabla f(x^{(k)}) = \begin{bmatrix} u \\ v \end{bmatrix}。$$

若 $u \geq 0$, 则停止计算, $x^{(k)}$ 为KKT点; 如果 u 包含负分量, 则选择一个负分量, 如 u_j , 去掉 A_1 对应 u_j 的行, 转3。

6.计算 $\hat{b} = b_2 - A_2 x^{(k)}$, $\hat{d} = A_2 d^{(k)}$, 转7。

7.若 $\hat{d} \geq 0$, 则从 $x^{(k)}$ 出发, 沿 $d^{(k)}$ 进行一维搜索

$$\min f(x^{(k)} + \lambda d^{(k)}) = f(x^{(k)} + \lambda_k d^{(k)})$$

令 $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$, 转9; 否则, 转8。

8. 计算 $\lambda_{\max} = \min \left\{ \frac{\hat{b}_i}{\hat{d}_i} \mid \hat{d}_i < 0 \right\}$, 求解

$$\min f(x^{(k)} + \lambda d^{(k)})$$

$$s.t. \quad 0 \leq \lambda \leq \lambda_{\max}$$

得最优解 λ_k , 令 $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$, 转9。

9. 确定 $x^{(k+1)}$ 的起作用约束, 修改 A_1, A_2 及 b_1, b_2 , 置 $k := k + 1$, 返回3。

用Rosen梯度投影法求解


$$\min f(x) = 2x_1^2 + 2x_2^2 - 2x_1x_2 - 4x_1 - 6x_2$$

$$s.t. \quad -x_1 - x_2 \geq -2$$

$$-x_1 - 5x_2 \geq -5$$

$$x_1 \geq 0$$

$$x_2 \geq 0$$



$$\text{解: } x^{(1)} = (0, 0)^T, I = \{3, 4\}$$

$$\nabla f(x) = (4x_1 - 2x_2 - 4, 4x_2 - 2x_1 - 6)^T$$

$$A_1 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, A_2 = \begin{pmatrix} -1 & -1 \\ -1 & -5 \end{pmatrix}, b_1 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, b_2 = \begin{pmatrix} -2 \\ -5 \end{pmatrix}$$

$$\Rightarrow d^{(1)} = -P \nabla f(x^{(1)}) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$P = I - M^T (M M^T)^{-1} M$$

$$\text{令 } W = (A_1 A_1^T)^{-1} A_1 \nabla f(x^{(1)}) = \begin{pmatrix} -4 \\ -6 \end{pmatrix} = \begin{pmatrix} u_1 \\ u_2 \end{pmatrix}$$


修正 A_1 , 去掉 A_1 中对应 $u_2 = -6$ 的行, 得到

$$\hat{A}_1 = \begin{pmatrix} 1 & 0 \end{pmatrix} = M$$

$$\Rightarrow P = I - M^T (M M^T)^{-1} M = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix}$$

$$\Rightarrow d^{(1)} = -P \nabla f(x^{(1)}) = \begin{pmatrix} 0 \\ 6 \end{pmatrix}$$

$\nabla f(x^{(1)})$



求步长 λ_1 :


$$\begin{cases} \min f(x^{(1)} + \lambda d^{(1)}) \\ s.t. \quad 0 \leq \lambda \leq \lambda_{\max} \end{cases}$$

$$\therefore \hat{b} = b_2 - A_2 x^{(1)} = \begin{bmatrix} -2 \\ -5 \end{bmatrix}, \hat{d} = A_2 d^{(1)} = \begin{bmatrix} -6 \\ -30 \end{bmatrix}$$

$$\therefore \lambda_{\max} = \min \left\{ \frac{-2}{-6}, \frac{-5}{-30} \right\} = \frac{1}{6}$$

$$\Rightarrow \lambda_1 = \frac{1}{6}$$

$$\therefore x^{(2)} = x^{(1)} + \lambda_1 d^{(1)} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$



第二次迭代

$$I = \{2, 3\}, \nabla f(x^{(2)}) = \begin{bmatrix} -6 \\ -2 \end{bmatrix}$$

$$A_1 = \begin{pmatrix} -1 & -5 \\ 1 & 0 \end{pmatrix}, A_2 = \begin{pmatrix} -1 & -1 \\ 0 & 1 \end{pmatrix}, b_1 = \begin{pmatrix} -5 \\ 0 \end{pmatrix}, b_2 = \begin{pmatrix} -2 \\ 0 \end{pmatrix}$$

$$P = I - A_1^T (A_1 A_1^T)^{-1} A_1 = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}, \quad \therefore d^{(2)} = -P \nabla f(x^{(2)}) = 0$$

$$\text{令 } W = (A_1 A_1^T)^{-1} A_1 \nabla f(x^{(2)}) = \begin{pmatrix} \frac{2}{5} \\ -\frac{28}{5} \end{pmatrix} = \begin{pmatrix} u_1 \\ u_2 \end{pmatrix}$$

从 A_1 中去掉 u_2 所对应的第二行,


$$\hat{A}_1 = \begin{pmatrix} -1 & -5 \end{pmatrix}$$

$$\hat{P} = I - \hat{A}_1^T (\hat{A}_1 \hat{A}_1^T)^{-1} \hat{A}_1 = \begin{pmatrix} \frac{25}{26} & -\frac{5}{26} \\ -\frac{5}{26} & \frac{1}{26} \end{pmatrix}$$

$$d^{(2)} = -\hat{P} \nabla f(x^{(2)}) = \frac{14}{13} \begin{pmatrix} 5 \\ -1 \end{pmatrix}, \text{取 } d^{(2)} = \begin{pmatrix} 5 \\ -1 \end{pmatrix}$$

$$\text{则 } \hat{b} = b_2 - A_2 x^{(2)} = \begin{pmatrix} -1 \\ -1 \end{pmatrix}, \hat{d} = A_2 d^{(2)} = \begin{pmatrix} -4 \\ -1 \end{pmatrix}$$

$$\therefore \lambda_{\max} = \min \left\{ \frac{-1}{-4}, \frac{-1}{-1} \right\} = \frac{1}{4}$$



$$\text{求步长 } \lambda_2 : \begin{cases} \min f(x^{(2)} + \lambda d^{(2)}) \\ s.t. \quad 0 \leq \lambda \leq \frac{1}{4} \end{cases}$$

$$\text{得 } \lambda_2 = \frac{7}{31}, \therefore x^{(3)} = x^{(2)} + \lambda_2 d^{(2)} = \left(\frac{35}{31}, \frac{24}{31} \right)^T$$

第三次迭代

$$I = \{2\}, \nabla f(x^{(3)}) = \left(-\frac{32}{31}, -\frac{160}{31} \right)^T$$

$$A_1 = (-1 \ -5), A_2 = \begin{pmatrix} -1 & -1 \\ 1 & 0 \\ 0 & 1 \end{pmatrix}, b_1 = (-5), b_2 = \begin{pmatrix} -2 \\ 0 \\ 0 \end{pmatrix}$$

$$P = I - A_1^T (A_1 A_1^T)^{-1} A_1 = \frac{1}{26} \begin{pmatrix} 25 & -5 \\ -5 & 1 \end{pmatrix}, d^{(3)} = 0,$$

$$W = \frac{32}{31} > 0, \Rightarrow x^{(3)} \text{ 是 } KKT \text{ 点。}$$

Wolfe既约梯度法

$$\min f(x)$$

$$s.t. \quad Ax = b, \quad x \geq 0$$

$A_{m \times n}$, $r(A) = m$, $b_{m \times 1}$, f 是 E^n 上的连续可微函数

基本思想： 借鉴求解线性规划的单纯形算法，选择某些变量为基变量，其它的作为非基变量，将基变量用非基变量表示，并从目标函数中消去基变量，得到以非基变量为自变量的简化的目标函数，进而利用此函数的负梯度构造下降可行方向。

既约梯度： 简化目标函数关于非基变量的梯度。

$$A = (B, N), \quad x = \begin{pmatrix} x_B \\ x_N \end{pmatrix}$$

$$\min f(x_B, x_N)$$

$$s.t. \quad Bx_B + Nx_N = b$$

$$x_B, x_N \geq 0$$



$$\min F(x_N)$$

$$s.t. \quad x_B, x_N \geq 0$$

$$x_B = B^{-1}b - B^{-1}Nx_N$$

$$\Rightarrow F(x_N) = f(x_B(x_N), x_N)$$

$f(x)$ 的既约梯度为

$$r(x_N) = \nabla F(x_N)$$

$$= \nabla_{x_N} f(x) - (B^{-1}N)^T \nabla_{x_B} f(x)$$

确定下降可行方向 $d^{(k)}$

$$d^{(k)} = \begin{pmatrix} d_B^{(k)} \\ d_N^{(k)} \end{pmatrix}, d_B^{(k)} \text{ 和 } d_N^{(k)} \text{ 分别对应基变量和非基变量。}$$

定义 $d_N^{(k)}$, 使得

$$d_{N_j}^{(k)} = \begin{cases} -x_{N_j}^{(k)} r_j(x_N^{(k)}) & \text{当 } r_j(x_N^{(k)}) > 0 \\ -r_j(x_N^{(k)}) & \text{当 } r_j(x_N^{(k)}) \leq 0 \end{cases}$$

为得到可行方向, 应有 $Ad^{(k)} = 0$

$$\text{即 } Bd_B^{(k)} + Nd_N^{(k)} = 0$$

$$\therefore \text{取 } d_B^{(k)} = -B^{-1}Nd_N^{(k)}$$

$$\Rightarrow d^{(k)} = \begin{pmatrix} -B^{-1}Nd_N^{(k)} \\ d_N^{(k)} \end{pmatrix}$$

$$\begin{aligned} r(x_N) &= \nabla F(x_N) \\ &= \nabla_{x_N} f(x) - (B^{-1}N)^T \nabla_{x_B} f(x) \end{aligned}$$

定理 设 x 是可行解, $A = (B, N)$ 是 $m \times n$ 矩阵, B 为 m 阶可逆矩阵, $x = (x_B^T, x_N^T)^T$, $x_B > 0$, 函数 f 在点 x 处可微, 又设

$$d = \begin{pmatrix} -B^{-1}Nd_N \\ d_N \end{pmatrix},$$

其中
$$d_{N_j} = \begin{cases} -x_{N_j} r_j(x_N) & r_j(x_N) > 0 \\ -r_j(x_N) & r_j(x_N) \leq 0 \end{cases}$$

如果 $d \neq 0$, 则 d 是下降可行方向, 而且 $d = 0$ 的充要条件是 x 为 KKT 点。

证明：根据方向 d 的定义，

$$Ad = Bd_B + Nd_N$$

$$d_{N_j} = \begin{cases} -x_{N_j} r_j(x_N), & r_j(x_N) > 0 \\ -r_j(x_N) & r_j(x_N) \leq 0 \end{cases}$$

$$= B(-B^{-1}Nd_N) + Nd_N = 0$$

注意 $x_B > 0$ ，且当 $x_{N_j} = 0$ 时，有 $d_{N_j} \geq 0$ ，

所以， d 为可行方向。由于

$$\begin{aligned} \nabla f(x)^T d &= \nabla_{x_B} f(x)^T d_B + \nabla_{x_N} f(x)^T d_N \\ &= \nabla_{x_B} f(x)^T (-B^{-1}Nd_N) + \nabla_{x_N} f(x)^T d_N \\ &= r(x_N)^T d_N \end{aligned}$$

当 $d_N \neq 0$ 时， $r(x_N)^T d_N < 0$ ，因此 d 是下降方向。

$\Rightarrow d$ 为下降可行方向。

$$\begin{aligned} r(x_N) &= \nabla F(x_N) \\ &= \nabla_{x_N} f(x) - (B^{-1}N)^T \nabla_{x_B} f(x) \end{aligned}$$

设 x 是 KKT 点, 则存在乘子 $w_B, w_N \geq 0$ 和 v , 使得

$$\begin{bmatrix} \nabla_{x_B} f(x) \\ \nabla_{x_N} f(x) \end{bmatrix} - \begin{bmatrix} B^T \\ N^T \end{bmatrix} v - \begin{bmatrix} w_B \\ w_N \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$w_B^T x_B = 0$$

$$w_N^T x_N = 0 \quad (*)$$

$$d_{N_j} = \begin{cases} -x_{N_j} r_j(x_N), & r_j(x_N) > 0 \\ -r_j(x_N) & r_j(x_N) \leq 0 \end{cases}$$

由于 $x_B > 0$, 所以 $w_B = 0 \Rightarrow v = (B^T)^{-1} \nabla_{x_B} f(x)$

因此 $w_N = \nabla_{x_N} f(x) - (B^{-1}N)^T \nabla_{x_B} f(x)$

$$= r(x_N) \geq 0$$

由 $(*)$, 得 $r(x_N)^T x_N = 0 \Rightarrow d = 0$.

$$r(x_N) = \nabla F(x_N)$$

$$= \nabla_{x_N} f(x) - (B^{-1}N)^T \nabla_{x_B} f(x)$$

" \Rightarrow "已知 $d = 0$, 则 $r(x_N)$ 的分量均非负。令

$$\begin{aligned} w_N &= r(x_N) \\ &= \nabla_{x_N} f(x) - (B^{-1}N)^T \nabla_{x_B} f(x) \geq 0 \end{aligned}$$

又令 $w_B = 0, v = (B^T)^{-1} \nabla_{x_B} f(x)$, 则有

$$\begin{bmatrix} \nabla_{x_B} f(x) \\ \nabla_{x_N} f(x) \end{bmatrix} - \begin{bmatrix} B^T \\ N^T \end{bmatrix} \begin{bmatrix} v \\ w_N \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$w_B^T x_B = 0$$

$$w_N^T x_N = 0$$

$$d_{N_j} = \begin{cases} -x_{N_j} r_j(x_N), & r_j(x_N) > 0 \\ -r_j(x_N) & r_j(x_N) \leq 0 \end{cases}$$

成立, 所以, x 是 KKT 点。

确定步长

为保持 $x^{(k+1)} \geq 0$

即 $x_j^{(k+1)} = x_j^{(k)} + \lambda d_j^{(k)} \geq 0, j = 1, 2, \dots, n$

当 $d_j^{(k)} \geq 0$ 时, 取 $\lambda \geq 0$

当 $d_j^{(k)} < 0$ 时, 应取 $\lambda \leq \frac{x_j^{(k)}}{-d_j^{(k)}}$

$$\lambda_{\max} = \begin{cases} \infty & \text{当 } d^{(k)} \geq 0 \\ \min \left\{ -\frac{x_j^{(k)}}{d_j^{(k)}} \mid d_j^{(k)} < 0 \right\} & \text{其他情形} \end{cases}$$

步骤

1. 给定初始可行点 $x^{(1)}$, 允许误差 $\varepsilon > 0$, 置 $k = 1$ 。
2. 从 $x^{(k)}$ 中选择 m 个最大分量, 它们的下标集记为 J_k ,
 A 的第 j 列记为 p_j , 令

B 是由 $\{p_j \mid j \in J_k\}$ 构成的 m 阶矩阵

N 是由 $\{p_j \mid j \notin J_k\}$ 构成的 $m \times (n - m)$ 阶矩阵

计算 $r(x_N) = \nabla_{x_N} f(x_B(x_N), x_N) - (B^{-1}N)^T \nabla_{x_B} f(x_B(x_N), x_N)$

计算
$$d_{N_j}^{(k)} = \begin{cases} -x_{N_j}^{(k)} r_j(x_N^{(k)}) & r_j(x_N^{(k)}) > 0 \\ -r_j(x_N^{(k)}) & r_j(x_N^{(k)}) \leq 0 \end{cases}$$

$$d_B^{(k)} = -B^{-1}Nd_N^{(k)}, \text{得搜索方向 } d^{(k)} = \begin{pmatrix} d_B^{(k)} \\ d_N^{(k)} \end{pmatrix}.$$

3. 若 $\|d^{(k)}\| \leq \varepsilon$, 则停止计算, 得点 $x^{(k)}$; 否则, 转4。

4. 计算 $\lambda_{\max} = \begin{cases} \infty & d^{(k)} \geq 0 \\ \min \left\{ -\frac{x_j^{(k)}}{d_j^{(k)}} \mid d_j^{(k)} < 0 \right\} & \text{否则} \end{cases}$

从 $x^{(k)}$ 出发, 沿 $d^{(k)}$ 进行一维搜索:

$$\begin{aligned} & \min f(x^{(k)} + \lambda d^{(k)}) \\ & s.t. \quad 0 \leq \lambda \leq \lambda_{\max} \end{aligned}$$

得到最优解 λ_k 。

5. 令 $x^{(k+1)} = x^{(k)} + \lambda_k d^{(k)}$, 置 $k := k + 1$, 返回2。

收敛性

定理： 设问题

$$\min f(x)$$

$$s.t. \quad Ax = b, \quad x \geq 0$$

中 f 是 E^n 上的连续可微函数，若 A 的任意 m 列均线性无关且所有基本可行解非退化，则 $Wolfe$ 既约梯度法产生的点列 $\{x^{(k)}\}$ 任意聚点是 KKT 点。

例: $\min 2x_1^2 + x_2^2$


$s.t. \quad x_1 - x_2 + x_3 = 2$

$-2x_1 + x_2 + x_4 = 1$

$x_j \geq 0, j = 1, 2, 3, 4$

初始可行点 $x^{(1)} = (1, 3, 4, 0)^T$

$\nabla f(x) = (4x_1, 2x_2, 0, 0)^T \quad \nabla f(x^{(1)}) = (4, 6, 0, 0)^T$



第一次迭代

$J_1 = \{2, 3\}$

$x_B = \begin{bmatrix} x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 3 \\ 4 \end{bmatrix} \quad x_N = \begin{bmatrix} x_1 \\ x_4 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$

$$B = \begin{bmatrix} -1 & 1 \\ 1 & 0 \end{bmatrix} \quad B^{-1} = \begin{bmatrix} 0 & 1 \\ 1 & 1 \end{bmatrix} \quad N = \begin{bmatrix} 1 & 0 \\ -2 & 1 \end{bmatrix}$$


$$r(x_N^{(1)}) = \begin{bmatrix} 4 \\ 0 \end{bmatrix} - \left(\begin{bmatrix} 0 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ -2 & 1 \end{bmatrix} \right)^T \begin{bmatrix} 6 \\ 0 \end{bmatrix} = \begin{bmatrix} 4 \\ 0 \end{bmatrix} - \begin{bmatrix} -2 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 6 \\ 0 \end{bmatrix} = \begin{bmatrix} 16 \\ -6 \end{bmatrix}$$

$$d_N^{(1)} = \begin{bmatrix} d_1^{(1)} \\ d_4^{(1)} \end{bmatrix} = \begin{bmatrix} -16 \\ 6 \end{bmatrix} \quad d_B^{(1)} = \begin{bmatrix} d_2^{(1)} \\ d_3^{(1)} \end{bmatrix} = - \begin{bmatrix} 0 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ -2 & 1 \end{bmatrix} \begin{bmatrix} -16 \\ 6 \end{bmatrix} = \begin{bmatrix} -38 \\ -22 \end{bmatrix}$$

$$\Rightarrow d^{(1)} = (-16, -38, -22, 6)^T$$

$$\lambda_{\max} = \min \left\{ -\frac{1}{-16}, -\frac{3}{-38}, -\frac{4}{-22} \right\} = \frac{1}{16}$$

求解问题 $\begin{cases} \min f(x^{(1)} + \lambda d^{(1)}) \\ s.t. \quad 0 \leq \lambda \leq \frac{1}{16} \end{cases}$ 得到 $\lambda_1 = \frac{1}{16}, \Rightarrow x^{(2)} = \left(0, \frac{5}{8}, \frac{21}{8}, \frac{3}{8} \right)^T$



第二次迭代


$$J_2 = \{2, 3\}$$

$$\nabla f(x^{(2)}) = \left(0, \frac{5}{4}, 0, 0\right)^T \quad x_B^{(2)} = \begin{bmatrix} x_2 \\ x_3 \end{bmatrix} \quad x_N^{(2)} = \begin{bmatrix} x_1 \\ x_4 \end{bmatrix}$$

$$r(x_N^{(2)}) = \begin{bmatrix} \frac{5}{2} \\ -\frac{5}{4} \end{bmatrix} \quad d_N^{(2)} = \begin{bmatrix} d_1^{(2)} \\ d_4^{(2)} \end{bmatrix} = \begin{bmatrix} 0 \\ \frac{5}{4} \end{bmatrix} \quad d_B^{(2)} = \begin{bmatrix} d_2^{(2)} \\ d_3^{(2)} \end{bmatrix} = \begin{bmatrix} -\frac{5}{4} \\ -\frac{5}{4} \end{bmatrix}$$

$$\Rightarrow d^{(2)} = \left(0, -\frac{5}{4}, -\frac{5}{4}, \frac{5}{4}\right)^T \quad \lambda_{\max} = \min \left\{ \frac{\frac{5}{8}}{\frac{5}{4}}, \frac{\frac{21}{8}}{\frac{5}{4}} \right\} = \frac{1}{2}$$

$$\text{求解问题} \begin{cases} \min f(x^{(2)} + \lambda d^{(2)}) \\ \text{s.t. } 0 \leq \lambda \leq \frac{1}{2} \end{cases} \Rightarrow \lambda_2 = \frac{1}{2}, \Rightarrow x^{(3)} = (0, 0, 2, 1)^T$$



第三次迭代

$$J_3 = \{3, 4\}$$

$$\nabla f(x^{(2)}) = (0, 0, 0, 0)^T$$

$$x_B^{(2)} = \begin{bmatrix} x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 2 \\ 1 \end{bmatrix} \quad x_N^{(2)} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$B = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad B^{-1} = B \quad N = \begin{bmatrix} 1 & -1 \\ -2 & 1 \end{bmatrix}$$

$$r(x_N^{(2)}) = \begin{bmatrix} 0 \\ 0 \end{bmatrix} - \left(\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & -1 \\ -2 & 1 \end{bmatrix} \right)^T \begin{bmatrix} 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$\Rightarrow d^{(2)} = (0, 0, 0, 0)^T$$

$$x^* = (0, 0, 2, 1)^T$$

广义既约梯度法

$$\min f(x)$$

$$s.t. \quad h_j(x) = 0, \quad j = 1, 2, \dots, m$$

$$l \leq x \leq u$$

其中 $f, h_j (j = 1, 2, \dots, m)$ 是连续可微函数, $x \in E^n$,
 $m \leq n$, l 和 u 都是 n 维列向量:

$$l = (l_1, \dots, l_n)^T, \quad u = (u_1, \dots, u_n)^T$$

$$\begin{aligned} \min & f(x) \\ \text{s.t.} & h(x) = 0 \\ & l \leq x \leq u \end{aligned}$$

其中 $h(x) = (h_1(x), \dots, h_m(x))^T$.

将变量区分为基变量向量 x_B 和非基变量向量 x_N

$$\frac{\partial h}{\partial x} = \begin{pmatrix} \frac{\partial h_1}{\partial x_1} & \dots & \frac{\partial h_1}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial h_m}{\partial x_1} & \dots & \frac{\partial h_m}{\partial x_n} \end{pmatrix} = \left(\frac{\partial h}{\partial x_B}, \frac{\partial h}{\partial x_N} \right)$$

$h(x)$ 的 Jacobi
矩阵

假设 $\frac{\partial h}{\partial x_B}$ 可逆，则 x_B 可用 x_N 表示，所以把目标

函数化为：

$$F(x_N) = f(x_B(x_N), x_N)$$

求既约梯度 $r(x_N) = \nabla F(x_N)$

$$\mathrm{d}f = \left(\nabla_{x_B} f \right)^T \mathrm{d}x_B + \left(\nabla_{x_N} f \right)^T \mathrm{d}x_N$$

其中

$$\nabla_{x_B} f = \left(\frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_m} \right)^T$$


$$\nabla_{x_N} f = \left(\frac{\partial f}{\partial x_{m+1}}, \dots, \frac{\partial f}{\partial x_n} \right)^T$$


$$\mathrm{d}x_B = (\mathrm{d}x_1, \dots, \mathrm{d}x_m)^T$$

$$\mathrm{d}x_N = (\mathrm{d}x_{m+1}, \dots, \mathrm{d}x_n)^T.$$

由 $h(x) = 0$, 得

$$\left\{ \begin{array}{l} \mathrm{d}h_1 = \frac{\partial h_1}{\partial x_1} \mathrm{d}x_1 + \cdots + \frac{\partial h_1}{\partial x_n} \mathrm{d}x_n = 0 \\ \dots\dots\dots \\ \mathrm{d}h_m = \frac{\partial h_m}{\partial x_1} \mathrm{d}x_1 + \cdots + \frac{\partial h_m}{\partial x_n} \mathrm{d}x_n = 0 \end{array} \right.$$


$$\frac{\partial h}{\partial x_B} \mathrm{d}x_B + \frac{\partial h}{\partial x_N} \mathrm{d}x_N = 0$$


$$\mathrm{d}x_B = - \left(\frac{\partial h}{\partial x_B} \right)^{-1} \frac{\partial h}{\partial x_N} \mathrm{d}x_N$$

$$\begin{aligned}
 df &= \left(\nabla_{x_B} f \right)^T dx_B + \left(\nabla_{x_N} f \right)^T dx_N \\
 &= \left[\nabla_{x_N} f - \left(\left(\frac{\partial h}{\partial x_B} \right)^{-1} \frac{\partial h}{\partial x_N} \right)^T \nabla_{x_B} f \right]^T dx_N
 \end{aligned}$$

所以，既约梯度为：

$$r(x_N) = \frac{df}{dx_N} = \nabla_{x_N} f - \left(\left(\frac{\partial h}{\partial x_B} \right)^{-1} \frac{\partial h}{\partial x_N} \right)^T \nabla_{x_B} f.$$

其中 $\frac{df}{dx_N} = \left(\frac{df}{dx_{m+1}}, \dots, \frac{df}{dx_n} \right)^T$

确定搜索方向

给定一点 $x^{(k)}$ ，定义 $d_N^{(k)}$ ，使它的分量满足：

$$d_{N_j}^{(k)} = \begin{cases} 0 & \begin{array}{l} \text{当 } x_{N_j}^{(k)} = l_{N_j} \text{ 且 } r_j(x_N^{(k)}) > 0 \\ \text{或当 } x_{N_j}^{(k)} = u_{N_j} \text{ 且 } r_j(x_N^{(k)}) < 0 \end{array} \\ -r_j(x_N^{(k)}) & \text{其他情形} \end{cases}$$

确定步长

令 $\hat{x}_N = x_N^{(k)} + \lambda d_N^{(k)}$

使得 $l_N \leq \hat{x}_N \leq u_N$

求解非线性方程组: $h(y, \hat{x}_N) = 0$

得到 \hat{y} . 若 \hat{y} 满足

$$f(\hat{y}, x_N^{(k)}) < f(x_B^{(k)}, x_N^{(k)})$$

且 $l_B \leq \hat{y} \leq u_B$

则得到新的可行点 (\hat{y}, \hat{x}_N) ; 否则减少步长, 重复以上过程。

Frank-Wolfe方法

$$(1) \quad \begin{cases} \min f(x) \\ s.t. \quad Ax \geq b \\ \quad \quad Ex = e \end{cases}$$

$A_{m \times n}$, $r(A) = m$, $E_{l \times n}$, $f(x)$ 连续可微

$$\text{令 } S = \{x \mid Ax \geq b, Ex = e, x \in E^n\}$$

基本思想：在每次迭代中，将目标函数 $f(x)$ 线性化，通过解线性规划求得下降可行方向，进而沿此方向在可行域内做一维搜索。

任取 $x^{(k)} \in S$, 在 $x^{(k)}$ 处以 $f(x)$ 的一阶 $Taylor$ 展开式作为 $f(x)$ 的线性逼近函数:

$$\begin{aligned} f_L(x) &= f(x^{(k)}) + \nabla f(x^{(k)})^T (x - x^{(k)}) \\ &= f(x^{(k)}) - \nabla f(x^{(k)})^T x^{(k)} + \nabla f(x^{(k)})^T x \end{aligned}$$

求解线性规划问题

$$\begin{array}{ll} \min & f_L(x) \\ \text{s.t.} & x \in S \end{array} \quad \longleftrightarrow \quad (2) \quad \begin{cases} \min & \nabla f(x^{(k)})^T x \\ \text{s.t.} & x \in S \end{cases}$$

设问题**(2)**存在有限最优解 $y^{(k)}$.

求解**(2)**有下列两种情形之一:

1. 若 $\nabla f(x^{(k)})^T (y^{(k)} - x^{(k)}) = 0$, 则停止迭代, $x^{(k)}$ 是 (1) 的 *KKT* 点。

2. 若 $\nabla f(x^{(k)})^T (y^{(k)} - x^{(k)}) \neq 0$, 则必有

$$\nabla f(x^{(k)})^T (y^{(k)} - x^{(k)}) < 0$$

$\Rightarrow y^{(k)} - x^{(k)}$ 为 $x^{(k)}$ 处的下降方向。

$\because S$ 是凸集, \therefore 对 $\forall \lambda \in (0, 1)$, 有

$$\lambda y^{(k)} + (1 - \lambda)x^{(k)} = x^{(k)} + \lambda(y^{(k)} - x^{(k)}) \in S$$

$\Rightarrow y^{(k)} - x^{(k)}$ 为 $x^{(k)}$ 处的可行方向。

$\Rightarrow y^{(k)} - x^{(k)}$ 为 $x^{(k)}$ 处的下降可行方向。

$$\begin{cases} \min \nabla f(x^{(k)})^T x \\ s.t. \quad x \in S \end{cases}$$

定理: 设 $y^{(k)}$ 是(2)的最优解, 且满足

$\nabla f(x^{(k)})^T (y^{(k)} - x^{(k)}) = 0$, 则 $x^{(k)}$ 是(1)的KKT点。

证明: 由 $\nabla f(x^{(k)})^T (y^{(k)} - x^{(k)}) = 0$, 得

$$\nabla f(x^{(k)})^T y^{(k)} = \nabla f(x^{(k)})^T x^{(k)}$$

$\because y^{(k)}$ 是(2)的最优解, 且 $x^{(k)} \in S$

$\therefore x^{(k)}$ 是(2)的KKT点 $\Rightarrow \exists w \geq 0 (w \in E^m), v \in E^n$ 使得

$$\begin{cases} \nabla f(x^{(k)}) - A^T w - E^T v = 0 \\ w^T (Ax^{(k)} - b) = 0 \\ Ex^{(k)} = e \end{cases} \quad \boxed{\begin{cases} \min \nabla f(x^{(k)})^T x \\ s.t. \quad x \in S \end{cases}}$$

这也是(1)的KKT条件 $\therefore x^{(k)}$ 是(1)的KKT点。

步骤

1. 给定初始可行点 $x^{(1)}$, 允许误差 $\varepsilon > 0$, 置 $k = 1$ 。

2. 求解线性规划问题

$$\begin{cases} \min \nabla f(x^{(k)})^T x \\ s.t. \quad x \in S \end{cases}$$

得到最优解 $y^{(k)}$ 。

3. 若 $|\nabla f(x^{(k)})^T (y^{(k)} - x^{(k)})| \leq \varepsilon$, 则停止, 得 $x^{(k)}$; 否则转4。

4. 从 $x^{(k)}$ 出发, 沿方向 $y^{(k)} - x^{(k)}$ 进行一维搜索:

$$\begin{cases} \min f(x^{(k)} + \lambda(y^{(k)} - x^{(k)})) \\ s.t. \quad 0 \leq \lambda \leq 1 \end{cases}$$

得最优解 λ_k 。

5. $x^{(k+1)} = x^{(k)} + \lambda_k(y^{(k)} - x^{(k)})$, 置 $k := k + 1$, 返回2。

例：

$$\begin{cases} \min f(x) = 4x_1^2 + (x_2 - 2)^2 \\ s.t. \quad -2 \leq x_1 \leq 2 \\ \quad \quad -1 \leq x_2 \leq 1 \end{cases}$$

解：取初始点 $x^{(1)} = (-2, -1)^T$

第一次迭代

$$\nabla f(x^{(1)}) = (-16, -6)^T$$

求

$$\begin{cases} \min \nabla f(x^{(1)})^T x = -16x_1 - 6x_2 \\ s.t. \quad -2 \leq x_1 \leq 2 \\ \quad \quad -1 \leq x_2 \leq 1 \end{cases}$$

得 $y^{(1)} = (2, 1)^T$.

从 $x^{(1)}$ 出发, 沿 $y^{(1)} - x^{(1)}$ 作一维搜索

$$\begin{cases} \min f(x^{(1)} + \lambda(y^{(1)} - x^{(1)})) \\ s.t. \quad 0 \leq \lambda \leq 1 \end{cases}$$

得 $\lambda_1 = 0.56$

$$\therefore x^{(2)} = x^{(1)} + \lambda_1(y^{(1)} - x^{(1)}) = (0.24, 0.12)^T$$

第二次迭代

$$\text{求} \begin{cases} \min \nabla f(x^{(2)})^T x = 1.92x_1 - 3.76x_2 \\ s.t. \quad -2 \leq x_1 \leq 2 \\ \quad \quad -1 \leq x_2 \leq 1 \end{cases}$$

$$\text{得} y^{(2)} = (-2, 1)^T.$$

从 $x^{(2)}$ 出发, 沿 $y^{(2)} - x^{(2)}$ 作一维搜索, 得 $x^{(3)}$,
这样继续下去, 得

$$y^{(1)} = y^{(3)} = y^{(5)} = \dots = (2, 1)^T$$

$$y^{(2)} = y^{(4)} = y^{(6)} = \dots = (-2, 1)^T$$

显然 $\lim_{k \rightarrow \infty} x^{(k)} = (0, 1)^T = x^*$.

